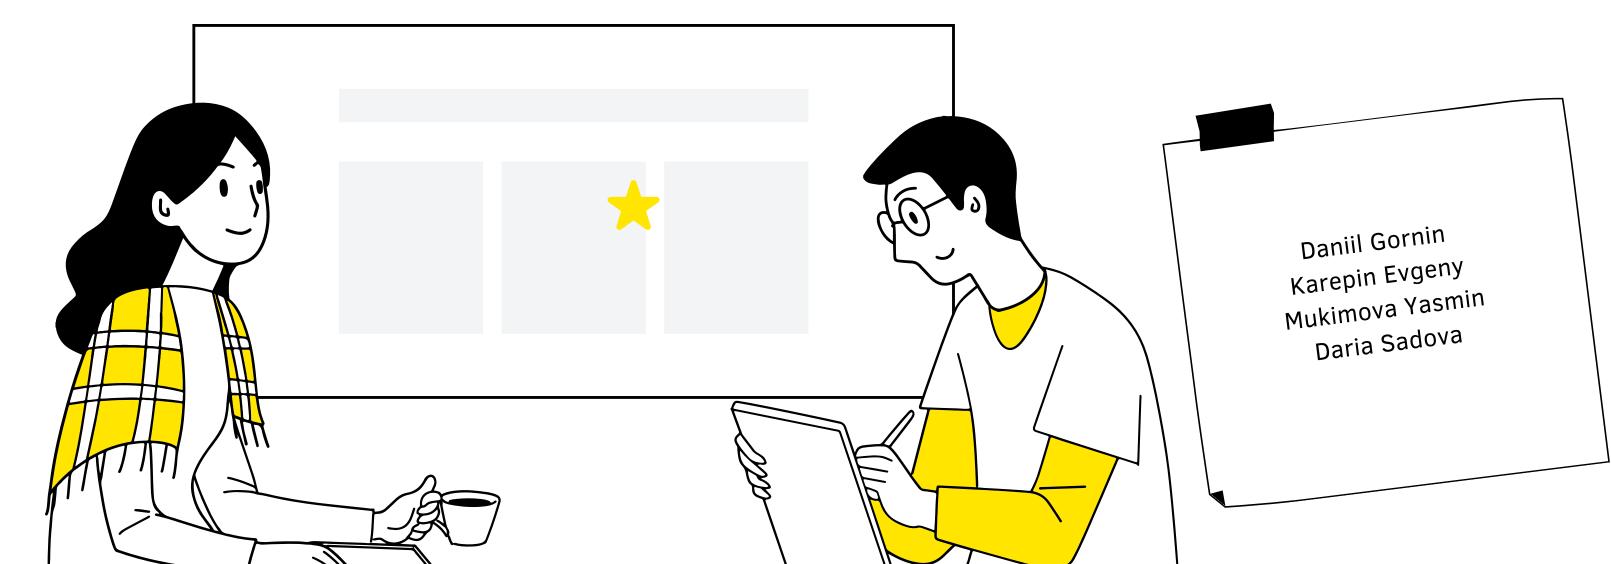
HSE GSB. Apartment price prediction



Participants

1 Daniil Gornin (ML Algorithms)

3

Mukimova Yasmin (API)

2 Karepin Evgeny (EDA)

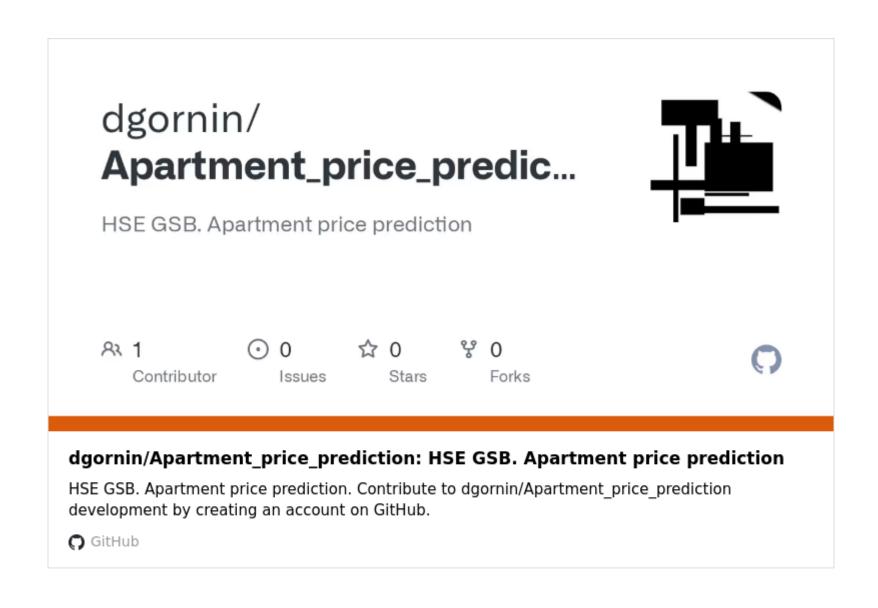
4

Daria Sadova (Data exploration)



Our project

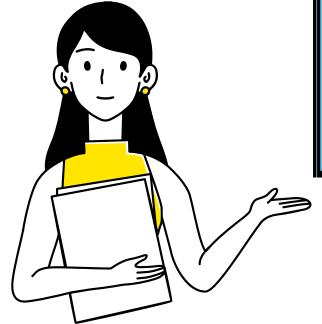




We have APT dataset to predict prices

train = pd.read csv("./hse-gsb-apartment-price-prediction/train.csv", delimiter=":")

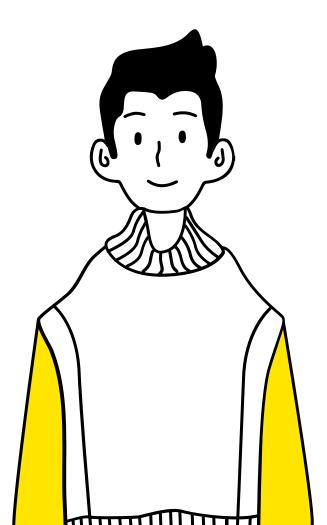
	ID	Категория	Заголовок	Опции продажи	Тип	Общая площадь		Площадь кухни	Этаж	Кол-во этажей в доме	 Кол-во совмещенных санузлов	Ремонт	Вид из окон	Расстояние до метро	
0	16592911	Недвижимость в Москве/ Продажа/ Продажа 2- комнат	2-комн. квартира, 70.03 м2	Возможна ипотека	Новостройка	70.03	41.8	13.7	2	17	 NaN	NaN	NaN	12 мин. на транспорте	(Новомосковск
1	17242255	Недвижимость в Москве/ Продажа/ Продажа 3- комнат	3-комн. квартира, 76.47 м2	Возможна ипотека	Новостройка	76.47	43.4	11.2	11	17	 NaN	NaN	Во двор	12 мин. на транспорте	(Новомосковск
2	193433104	Недвижимость в Москве/ Продажа/ Продажа 2- комнат	2-комн. квартира, 60.0 м2	NaN	Новостройка	60.00	38.0	12.0	5	20	 NaN	NaN	На улицу и двор	3 мин. на транспорте	Москва,СЗА Мно
3	140334219	Недвижимость в Москве/ Продажа/ Продажа 2- комнат	2-комн. квартира, 65.2 м2	Возможна ипотека	Новостройка	65.20	0.0	0.0	2	5	 NaN	NaN	На улицу и двор	NaN	Московская с
4	189844059	Недвижимость в Москве/ Продажа/ Продажа 1- комнат	1-комн. квартира, 38.18 м2	Возможна ипотека	Новостройка	38.18	17.3	8.1	1	3	 NaN	NaN	Во двор	33 мин. на транспорте	Моско гор



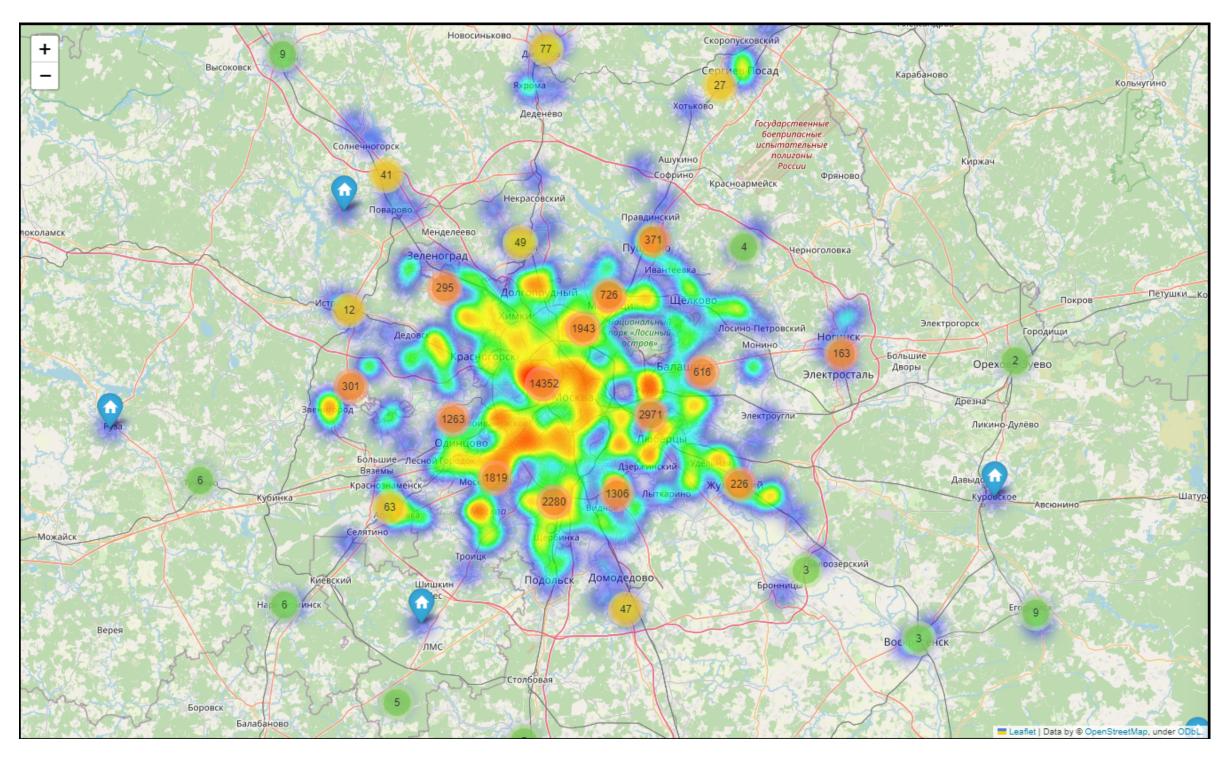
We have a lot of addresses what o do with them?

We have 1776 unique address, let's find coordinates of them

```
Note: if you want to parse data about coordinates by yourself then you will need to use Yandex API to use it create API key here crate api and then pass it to Client function
Note: if you want you can use already parsed data from json file here go to cell
Load data by your self
    from yandex geocoder import Client
    adr_to_cord = {}
    regions cord = {}
    t_adr_to_cord = {}
    t_regions_cord = {}
    client = Client("Yur API key")
    for i in range(0, len(train_address)):
        coordinates = client.coordinates(train_address[i])
        if coordinates:
            adr to cord[train address[i]] = {"latitude": float(coordinates[1]), "longitude": float(coordinates[0])}
            adr_to_cord[train_address[i]] = {"latitude": None, "longitude": None}
```



How data distributed?



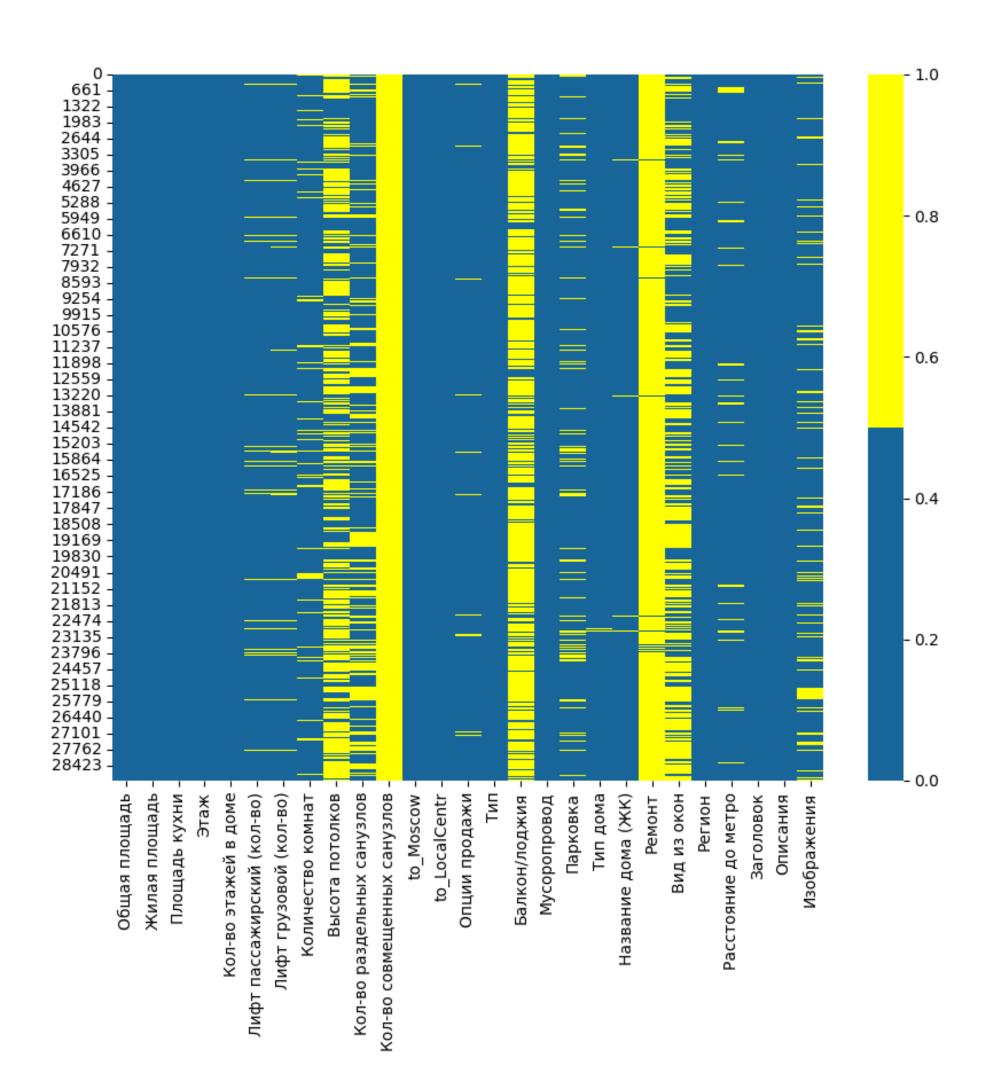
We can notice that all apts are placed in Moscow, or near it, so for the model we can add range to Moscow centre, and another metric as range to the local centre

Add distance

```
def haversine_np(lon1, lat1, lon2, lat2):
      lon1, lat1, lon2, lat2 = map(np.radians, [lon1, lat1, lon2, lat2])
      dlon = lon2 - lon1
      dlat = lat2 - lat1
      \overline{a} = \text{np.sin}(\text{dlat}/2.0)^{**2} + \text{np.cos}(\text{lat1}) * \text{np.cos}(\text{lat2}) * \text{np.sin}(\text{dlon}/2.0)^{**2}
     c = 2 * np.arcsin(np.sqrt(a))
      km = 6367 * c
      return km
✓ 0.0s
  to_Moscow = []
  to LocalCentr = []
  for index, row in df train.iterrows():
     to_Moscow.append(haversine_np(row['longitude'], row['latitude'], 37.6156, 55.7522))
  😯 to_LocalCentr.append(haversine_np(row['longitude'], row['latitude'], regions_cord[row['Регион']]['longitude'], regions_cord[row['Регион']]['latitude']))
  df_train['to_Moscow'] = to_Moscow
  df_train['to_LocalCentr'] = to_LocalCentr
✓ 1.0s
  to_Moscow = []
  to LocalCentr = []
  for index, row in df_test.iterrows():
      to_Moscow.append(haversine_np(row['longitude'], row['latitude'], 37.6156, 55.7522))
      to_LocalCentr.append(haversine_np(row['longitude'], row['latitude'], t_regions_cord[row['Регион']]['longitude'], t_regions_cord[row['Регион']]['latitude']))
  df_test['to_Moscow'] = to_Moscow
  df_test['to_LocalCentr'] = to_LocalCentr
  0.2s
```

Data exploration

Identify which parameters are posable helpful for the model: Target 'Стоимость' Continuous 'Общая площадь' 'Жилая площадь' 'Площадь кухни' 'Этаж' 'Кол-во этажей в доме' 'Лифт пассажирский (кол-во)' 'Лифт грузовой (кол-во)' 'Количество комнат' • 'Высота потолков' • 'Кол-во раздельных санузлов' • 'Кол-во совмещенных санузлов' 'to_Moscow' 'to LocalCentr' Categorical 'Опции продажи' ∘ 'Тип' 'Балкон/лоджия' 'Мусоропровод' 'Парковка' 'Тип дома' 'Название дома (ЖК)' 'Ремонт' 'Вид из окон' 'Регион' • For revue and posable changes 'Расстояние до метро' 'Заголовок' 'Описания' 'Изображения'



What to do?

We can see a lot of missing data in columns: 'Высота потолков', 'Кол-во раздельных санузлов', 'Кол-во совмещенных санузлов', 'Балкон/лоджия', 'Ремонт', 'Вид из окон'

We should exclude them from our model because this parameters will not give us relative the information

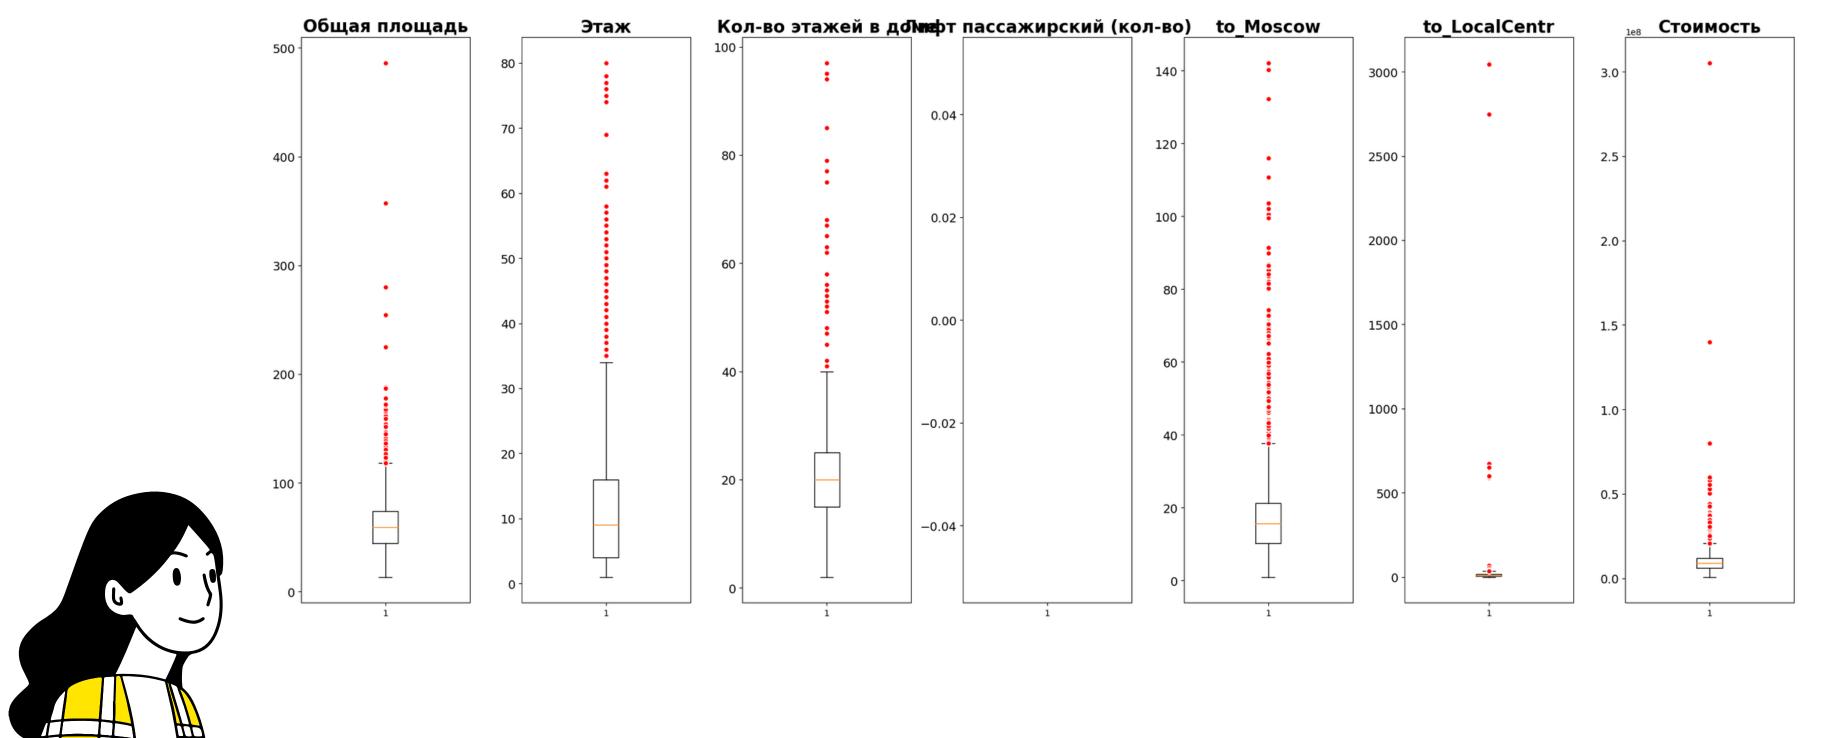


	Стоимость -	1	0.6	0.2	0.08	0.2	0.3	0.1	-0.05	0.4	-0.5	-0.07	1.00
	Общая площадь -	0.6	1	0.6	0.2	-0.02	0.04	0.009	-0.05	0.8	-0.09	-0.02	- 0.75
	Жилая площадь -	0.2	0.6	1	0.4	-0.09	-0.2	-0.09	0.01	0.6	0.1	0.03	- 0.50
	Площадь кухни -	0.08	0.2	0.4	1	-0.03	-0.09	-0.02	0.2	-0.02	-0.02	-0.04	0.50
	Этаж -	0.2	-0.02	-0.09	-0.03	1	0.6	0.2	0.07	-0.06	-0.2	0.008	- 0.25
	Кол-во этажей в доме -	0.3	0.04	-0.2	-0.09	0.6	1	0.3	0.05	-0.02	-0.3	-0.01	- 0.00
	Лифт пассажирский (кол-во) -	0.1	0.009	-0.09	-0.02	0.2	0.3	1	0.5	-0.04	-0.2	0.02	0.25
	Лифт грузовой (кол-во) -	-0.05	-0.05	0.01	0.2	0.07	0.05	0.5	1	-0.02	0.007	0.02	0.25
	Количество комнат -	0.4	0.8	0.6	-0.02	-0.06	-0.02	-0.04	-0.02	1	0.02	0.004	0.50
C O V	to_Moscow -	-0.5	-0.09	0.1	-0.02	-0.2	-0.3	-0.2	0.007	0.02	1	0.1	0.75
	to_LocalCentr -	-0.07	-0.02	0.03	-0.04	0.008	-0.01	0.02	0.02	0.004	0.1	1	
		Стоимость -	Общая площадь -	Жилая площадь -	Площадь кухни -	Этаж -	Кол-во этажей в доме -	Лифт пассажирский (кол-во) -	Лифт грузовой (кол-во) –	Количество комнат -	to_Moscow -	to_LocalCentr -	1.00

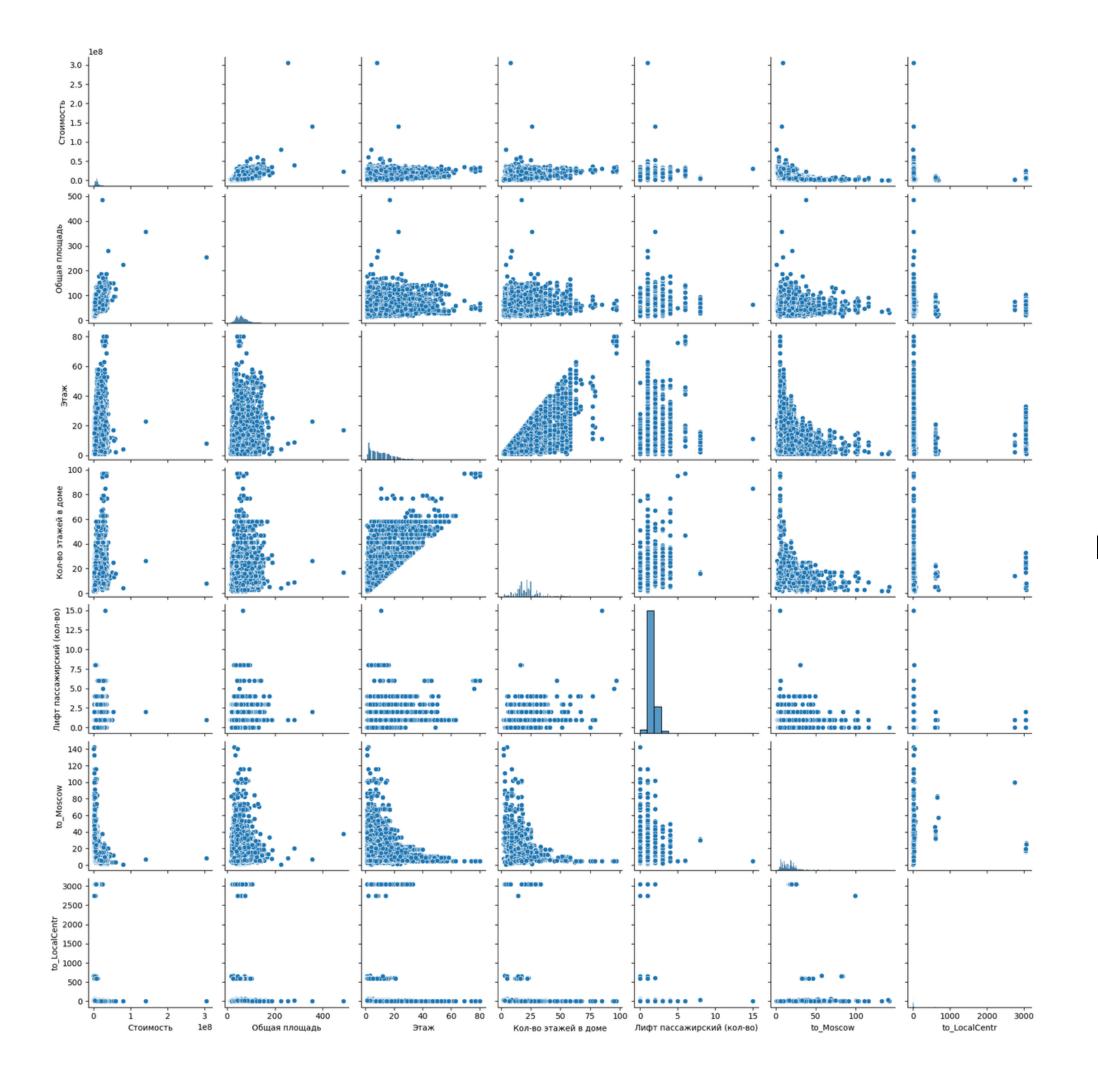
What to do?

You can notice that all the parameters depending on the area will cause multicollinearity, so you will have to leave only one of them in the model, the total area correlates with the price best of all, then we subtract it and throw it out 'Жилая площадь', 'Площадь кухни', 'Количество комнат'

Also there is multicollinearity in amount of different types of elevator so instead of different types our command used sum of types of elevator, but the result of the correlation was lower than just passenger elevator, so i lefted just amount of passenger elevators



There are quite a lot of outliers in the data, but they cannot be deleted due to the specifics of the data



linear dependence is observed for the area and the distance to Moscow to the price



```
Cope with null data
                                                                               + Code
                                                                                         + Markdown
       df_train[continuous + target].isnull().sum()
[23]
                                                                                                                                                                             Python
    Общая площадь
                                     0
     Этаж
    Кол-во этажей в доме
    Лифт пассажирский (кол-во)
                                  1096
    to_Moscow
    to_LocalCentr
                                     0
    Стоимость
    dtype: int64
        df_train['Лифт пассажирский (кол-во)'].mean()
[24]
                                                                                                                                                                             Python
... 1.2066337483898668
        df_train['Лифт пассажирский (кол-во)'] = df_train['Лифт пассажирский (кол-во)'].fillna(1)
     ✓ 0.0s
                                                                                                                                                                             Python
[25]
        df_test['Лифт пассажирский (кол-во)'] = df_test['Лифт пассажирский (кол-во)'].fillna(1)
     ✓ 0.0s
                                                                                                                                                                             Python
```



Analysis of categorical data

	Опции продажи	Тип	Мусоропровод	Парковка	Тип дома	Название дома (ЖК)	Регион
count	28584	29044	29044	25806	28827	28841	29044
unique	7	2	2	3	5	580	57
top	Долевое участие (214-Ф3), Возможна ипотека	Новостройка	Нет	подземная	Монолитный	ЖК «Хорошевский»	Москва
freq	22208	28655	28884	12427	25788	1158	20462

Column Регион is already partly used in range to Moscow centr column, and it have to many unique values it is better to do not encode it and use it

Column Название дома (ЖК) have to many unique it is inefficient to code it

For other we will use One-hot encoding for higher efficiency

```
categorical.remove('HasBaHue дома (ЖК)')
categorical.remove('Peruoh')

[28] ✓ 0.0s

Python
```

	Опции продажи_Альтернатива	Опции продажи_Альтернатива, Возможна ипотека	Опции продажи_Возможна ипотека		Опции продажи_Долевое участие (214-Ф3), Возможна ипотека		Опции продажи_Свободная продажа, Возможна ипотека	Тип_Вторичка	Тип_Новост
0	False	False	True	False	False	False	False	False	
1	False	False	True	False	False	False	False	False	
2	False	False	False	False	False	False	False	False	
3	False	False	True	False	False	False	False	False	
4	False	False	True	False	False	False	False	False	



Let's implement ML to solve the challenge

Gradient boosting

```
Gradient boosting
                                                                                                                                                       from sklearn.preprocessing import StandardScaler
       from sklearn model selection import train test split
       X = df train[continuous].join(df train dummies)
       y = df_train['Стоимость']
       X test submit = df test[continuous].join(df test dummies)
       scaler = StandardScaler()
       X[continuous] = scaler.fit_transform(X[continuous])
       scaler = StandardScaler()
       X_test_submit[continuous] = scaler.fit_transform(X_test_submit[continuous])
       X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
[36]
       from xgboost import XGBRegressor
       from sklearn.model_selection import GridSearchCV
       xgb = XGBRegressor(n_estimators=100000, learning_rate=0.001, tree_method='gpu_hist', eval_metric='rmsle')
       xgb.fit(X train, y train)
       predictions = xgb.predict(X test)

√ 3m 28.7s

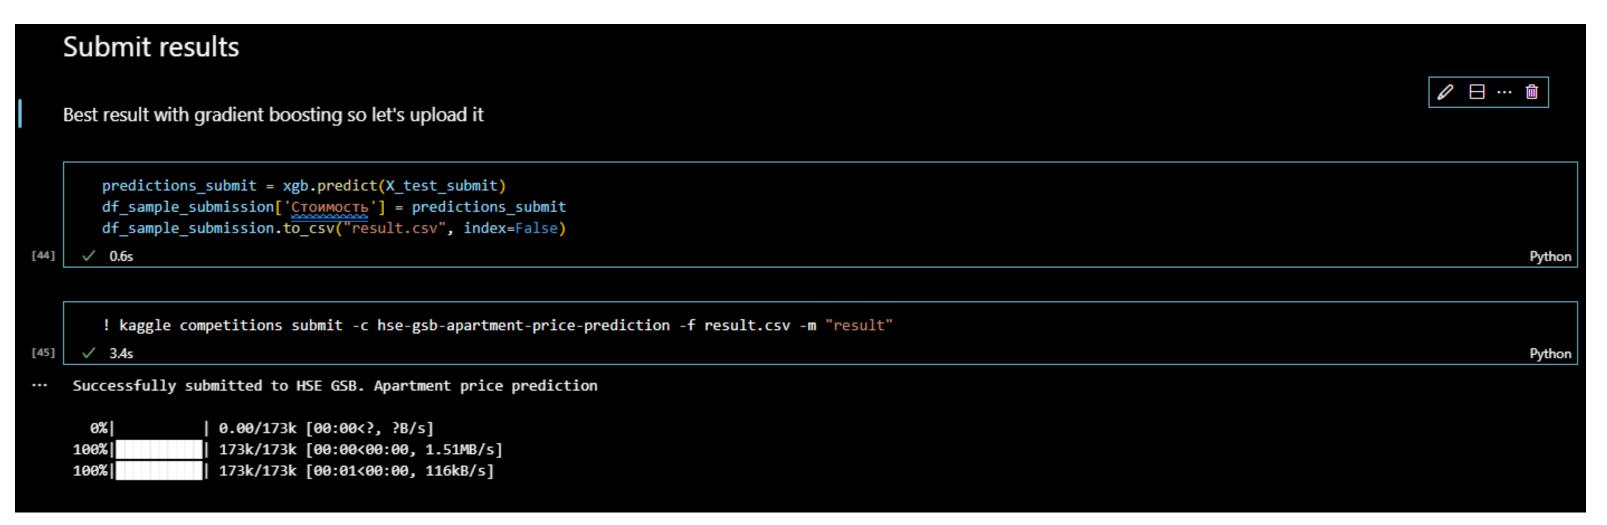
                                                                                                                                                                         Python
       from sklearn.metrics import mean_squared_log_error
       from math import sqrt
       sqrt(mean_squared_log_error(y_test, predictions))
     ✓ 0.0s
                                                                                                                                                                         Python
    0.08267688900709971
```

Linear regression model

```
Linear regression model
                                                                                                                                                                      from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
    from sklearn.linear_model import LinearRegression from sklearn.model_selection import GridSearchCV
     pipeline = Pipeline(
              ('ln', LinearRegression()),
  ✓ 0.1s
     pipeline.fit(X_train, y_train)
  ✓ 0.0s
          Pipeline
    ▶ LinearRegression
     from sklearn.metrics import mean_squared_log_error
     from math import sqrt
     res = pipeline.predict(X_test)
     a = res.mean()
     for i in range(len(res)):
         if res[i] < 0:
             res[i] = a
     sqrt(mean_squared_log_error(y_test, predictions))
 0.08267688900709971
```

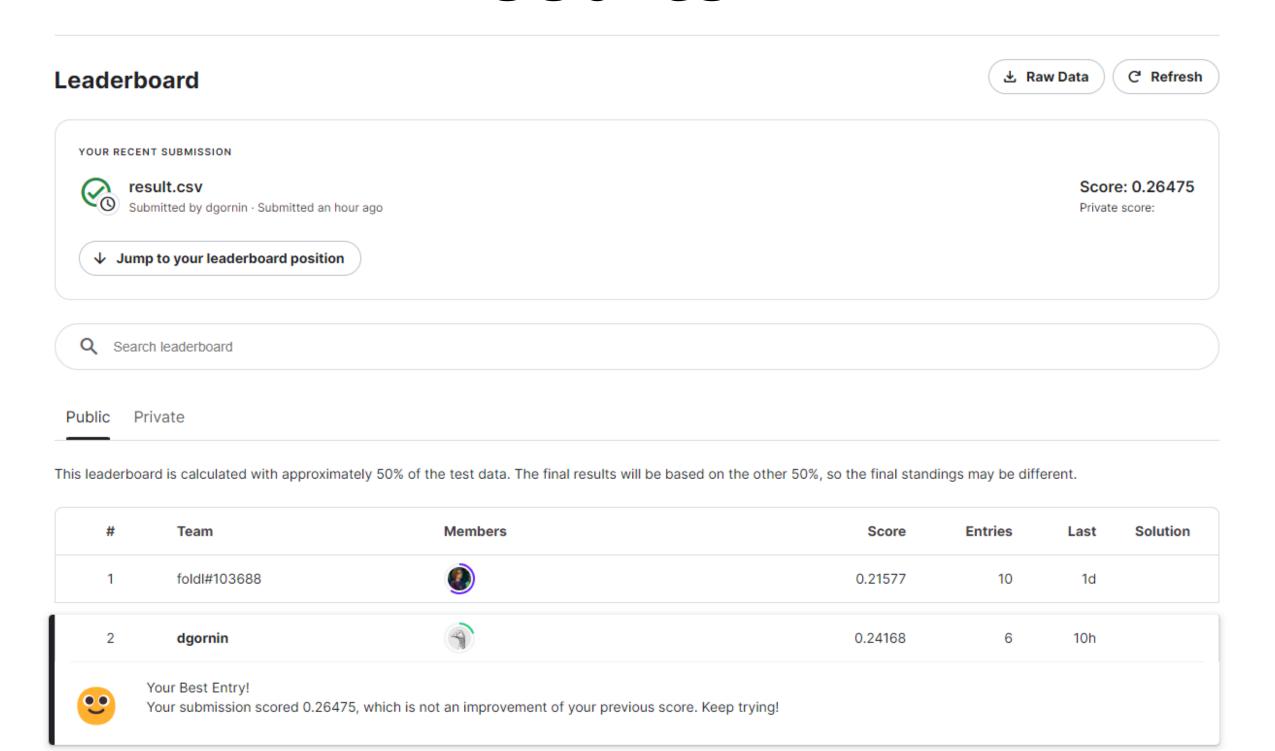


Submit results





Results



3	Nikita Jeanpaul	0.41048	20	10h
4	Максим Репин	0.42061	3	1d
5	Error 418	0.43267	3	9h

Thanks for your attention!

